



# **PROIECT**

## **Detectarea și segmentarea cancerului cerebral de tip meningiom**

**Studenți: Patrașcu Cosmin-Eusebiu**

**Stanciu Răducu-Ștefan**

**Grupa: 442B**



## Cuprins

Capitolul 1 : Introducere .....	4
1.1.Creierul.....	4
1.2. Meningiomul.....	4
1.3.Metoda Imagistică .....	5
Capitolul 2 : State of the art .....	7
2.1.Metode convenționale.....	7
2.1.1 Tehnica bazată pe prag .....	7
2.2.Metode supervizate. ....	8
2.2.1 Rețele neuronale artificiale (ANN) .....	8
2.2.2 K-nearest neighbor (KNN) .....	8
2.2.3 Support vector machine (SVM).....	9
2.3.Metode nesupervizate. ....	9
2.3.1.Segmentare bazată pe clustering .....	9
2.4.Metode hibride .....	9
Capitolul 3 : Descrierea Metodelor Propuse .....	10
3.1. Îmbunătățirea imaginilor .....	10
3.1.1. Modificarea contrastului, liniară pe porțiuni .....	10
3.1.2. Functia putere .....	11
3.1.3.Clipping .....	11
3.2. Segmentare .....	12
3.3. Operații morfologice .....	13
3.3.1. Dilatarea.....	13
3.3.2.Erodarea.....	14
Capitolul 4 : Rezultate obținute .....	15
4.1. Îmbunătățirea imaginilor .....	16
4.1.1. Modificarea contrastului, liniară pe porțiuni .....	16
4.1.2. Functia putere .....	17
4.1.3. Clipping .....	17
4.2. Segmentare .....	18



**UNIVERSITATEA POLITEHNICA BUCUREȘTI**  
**Facultatea de Electronică, Telecomunicații și Tehnologia informației**



4.3. Operații morfologice .....	18
4.4. Rezultate satisfăcătoare și nesatisfăcătoare.....	19
Capitolul 5 : Concluzii .....	21
Bibliografie .....	22

## Capitolul 1 : Introducere

### 1.1.Creierul

Creierul uman adult are un volum mediu de  $1350 \text{ cm}^3$ , o suprafață totală de  $1820 \text{ cm}^2$  și o grosime corticală medie de 2,7 mm (Pakkenberg și Gundersen, 1997). Conține aproximativ 100 de miliarde de neuroni, dintre care 20 de miliarde se află în cortexul cerebral (Herculano-Houzel, 2009). Fiecare neuron cortical are în medie 7000 de conexiuni sinaptice cu alți neuroni, rezultând un total de 0,15 cvadrilioane de sinapse și mai mult de 150.000 km de fibre nervoase mielinizate (Pakkenberg et al., 2003). Gyrificarea, adică pliarea suprafeței corticale, este considerată un mecanism de maximizare a numărului de neuroni corticali și de minimizare a lungimii totale a fibrelor în spațiul limitat din interiorul craniului (Zilles et al., 2013).

În ultimii ani, întrebarea ce anume determină pliarea corticală a atras atenția cercetătorilor din diverse domenii (Richman et al., 1975; VanEssen, 1997). După decenii de cercetări biologice, forțele fizice sunt acum din ce în ce mai mult recunoscute ca având un rol central în reglarea selecției tiparelor și în morfogeneza suprafeței (Smith, 2009; Bayly et al., 2013; Franze et al., 2013; Budday et al., 2014b; Ciarletta et al., 2014). Deși există un consens general privind importanța forțelor mecanice în timpul neurodezvoltării (Franze, 2014), până în prezent, biologia fizică a dezvoltării creierului uman rămâne insuficient studiată și puțin înțeleasă (Bayly et al., 2014) [1].

### 1.2. Meningiomul

Deși majoritatea meningiomelor sunt tumori încapsulate și benigne, cu un număr limitat de anomalii genetice, localizarea lor intracraniană duce adesea la consecințe grave și potențial letale. Ele sunt cele mai frecvent diagnosticate tumori primare ale creierului, reprezentând 33,8% din toate tumorile primare ale creierului și ale sistemului nervos central raportate în Statele Unite între 2002 și 2006. Susceptibilitatea ereditară la meningiom este sugerată atât de istoricul familial, cât

și de studiile asupra genelor candidate implicate în repararea ADN-ului. Persoanele cu anumite mutații în gena neurofibromatozei (NF2) prezintă un risc foarte crescut de a dezvolta meningiom. Expunerea la doze mari de radiații ionizante este un factor de risc bine stabilit pentru meningiom, iar dozele mai mici pot crește, de asemenea, riscul, deși tipurile și dozele exacte sunt controversate sau insuficient studiate. Deoarece femeile au de două ori mai multe șanse decât bărbații de a dezvolta meningiom și aceste tumori prezintă receptori hormonali, s-a emis ipoteza unui rol etiologic al hormonilor (atât endogeni, cât și exogeni). Influența factorilor imunologici asupra etiologiei meningiomului a fost în mare parte neexplorată. Creșterea interesului în cercetarea tumorilor cerebrale, împreună cu apariția unor noi instrumente genetice și moleculare în epidemiologia genetică și moleculară, oferă speranță pentru avansarea cunoștințelor privind cauzele meningiomului intracranian.

Comparativ cu tumorile gliale maligne, meningiomurile sunt relativ puțin studiate în ceea ce privește factorii de risc etiologic. Cercetarea meningiomului întâmpină mai multe provocări: (i) fiind o boală relativ rară, sunt necesare studii de amploare sau multicentrice pentru a obține suficiente cazuri; (ii) latența lungă a meningiomului, de 20–30 de ani sau mai mult, observată cel mai evident în studiile cu doze cunoscute de radiații ionizante, face dificilă stabilirea expunerii din cauza prejudecății de rememorare; (iii) prevalența bolii subclinice de până la 2,8% din populație, conform studiilor autopsiilor, sugerează că numărul persoanelor susceptibile este mult mai mare decât cel al persoanelor cu diagnostice confirmate clinic; și (iv) problema prejudecății de detecție – multe meningiomuri sunt descoperite incidental prin RMN-uri efectuate pentru afecțiuni precum traumatisme craniene sau probleme de sinusuri. Aceste meningiomuri descoperite întâmplător și o porțiune semnificativă a meningiomurilor descoperite primar sunt gestionate „conservativ,” adică prin observație, fără îndepărtare chirurgicală. O modalitate prin care epidemiologii pot minimiza prejudecata de detecție este să includă doar cazurile care au fost supuse îndepărtării chirurgicale și confirmării patologice, asigurând că meningiomul este semnificativ din punct de vedere clinic. Până în prezent, doar câteva studii epidemiologice asupra tumorilor intracraniene au avut suficientă putere statistică pentru a studia separat factorii de risc pentru meningiom [2].

### **1.3. Metoda Imagistică**

Imaginile din baza de date au fost obținute folosind imagistica prin rezonanță magnetică (IRM).

IRM este o metodă neinvazivă de cartografiere a structurii interne și a anumitor aspecte funcționale ale corpului. Utilizează radiații electromagnetice neionizante și pare a fi lipsită de pericole asociate expunerii. Tehnica folosește radiații de frecvență radio (RF) în prezența unor câmpuri magnetice controlate cu atenție pentru a produce imagini de înaltă calitate, secționale, ale corpului, în orice plan. Imaginea IRM este construită prin plasarea pacientului într-un magnet mare, care induce un câmp magnetic extern relativ puternic. Acest lucru determină alinierea nucleelor multor atomi din corp, inclusiv a hidrogenului, cu câmpul magnetic. Ulterior, aplicarea unui semnal RF determină eliberarea de energie din corp, care este detectată și utilizată pentru a construi imaginea IRM cu ajutorul unui computer [3].

## Capitolul 2 : State of the art

Recent, segmentarea tumorii cerebrale a devenit o sarcină comună în analiza imaginilor medicale datorită eficacității sale în diagnosticarea tipului, mărimii și locației tumorii prin metode automate. În ultimii ani, majoritatea metodelor pentru segmentare au devenit cele cu deep learning, datorită eficienței sale.[4]

### 2.1. Metode convenționale

#### 2.1.1 Tehnica bazată pe prag

Segmentarea cu tehnica bazată pe prag este o metodă rapidă și eficientă prin compararea intensității unui sau mai multor praguri. Tehnica include „prag global” și „prag local”. [5]

##### 2.1.1.1 Prag global

În metoda de prag global, intensitatea este cea mai bună proprietate pe care pixelii dintr-o regiune o pot împărtăși și depinde de ea pentru a determina raportul de intensitate dintre obiecte și fundal. Aceasta este o tehnică potrivită pentru o imagine IRM care conține obiecte cu contrast similar sau intensitate mare între obiecte

Cea mai comună și rapidă metodă de calcul este alegerea unei singure valori de prag pentru întreaga imagine. Astfel, este potrivit pentru segmentarea imaginilor care conțin obiecte cu intensitate omogenă și nu conține nicio formă constantă. [5]

##### 2.1.1.2 Prag local

Un prag local poate fi utilizat în mod eficient atunci când o valoare de prag nu poate fi determinată dintr-o histogramă pentru întreaga imagine și efectul de gradient este mic în ceea ce privește dimensiunea imaginii selectate sau nu poate oferi rezultate mai bune de segmentare cu un singur prag.

Metoda locală de prag calculează pragul pentru un pixel dintr-o vecinătate decât din întreaga imagine. [5]

## **2.2. Metode supervizate.**

Metodele de segmentarea supervizată necesită date etichetate, aceasta include o fază de antrenare, folosind datele etichetate pentru a crea o rețea care clasifică imaginile, și o fază de testare care este utilizată pentru a specifica etichetele datelor neetichetate pe baza caracteristicilor măsurate. [5]

### **2.2.1 Rețele neuronale artificiale (ANN)**

ANN este o tehnică de segmentare bazată pe rețeaua neuronală, de obicei este antrenată sau alimentată cu o cantitate semnificativă de date printr-o serie de noduri atunci când este creată pentru prima dată, unde fiecare pixel este reprezentat de un neuron. Antrenarea implică furnizarea intrării și antrenarea rețelei neuronale pentru cunoașterea conexiunilor și greutăților dintre noduri și instruirea rețelei despre cum să producă rezultatul dorit.

Extragerea caracteristicilor este primul pas în ANN; caracteristicile sunt extrase din imagini în așa fel încât să poată fi utilizate ca intrare pentru segmentare, iar următorul pas este segmentarea imaginii [5]

Deși un model ANN este capabil să proceseze date neorganizate și o analiză vizuală eficientă, este costisitor din punct de vedere economic și computațional și necesită un proces de instruire lung. [4]

### **2.2.2 K-nearest neighbor (KNN)**

Algoritmul KNN este o tehnică de segmentare bazată pe clasificare foarte simplă, ușor de implementat. Ideea KNN se bazează pe pixeli segregati care sunt clasificați în clase în funcție de corespondența lor cu caracteristicile unui set de pixeli similari care există unul lângă celălalt, unde este efectuat cel mai apropiat vecin neetichetat, apoi clasa sau eticheta este determinată folosind acei vecini. Pentru a prezice eticheta punctelor de testare, se estimează asemănarea sau distanța dintre cazurile de instruire și noile puncte de testare neetichetate. [5]



### **2.2.3 Support vector machine (SVM)**

SVM a fost folosit ca o abordare parametrică bazată pe nucleu pentru tratarea problemelor de clasificare supravegheată. Poate fi util în special pentru aplicațiile de clasificare cu mai multe domenii și poate prezenta o tehnică robustă pentru clasificarea binară.

Datorită capacității sale mari de clasificare, SVM a fost folosit des în domeniul segmentării tumorii cerebrale. SVM permite detectarea și localizarea tumorilor cerebrale în RMN, precum și segmentarea celulelor tumorale pentru a cunoaște dimensiunea tumorii în acea regiune segmentată. [5]

### **2.3. Metode nesupervizate.**

Metodele nesupravegheate nu se bazează pe date de antrenament etichetate manual; în schimb, caracteristicile omogene împreună pot fi grupate și numeroase clase pot fi decise automat printr-un algoritm care grupează pixeli similari

#### **2.3.1. Segmentare bazată pe clustering**

Segmentarea bazată pe clustering este un tip de metodă nesupravegheată pentru segmentarea datelor de imagine neetichetate în grupuri de pixeli păstrând intensități similare care împărtășesc unele caracteristici în același cluster și pixeli diferiți în grupuri diferite.

Metoda de clustering poate fi împărțită în două categorii, și anume hard clustering și soft clustering. În hard clustering, un pixel poate aparține unui singur grup de pixeli care are aceleași caracteristici și intensitate. Dar în soft clustering, rezultatul oferit este o probabilitate ca un pixel să aparțină la două sau mai multe dintre grupurile definite. [5]

### **2.4. Metode hibride**

Ideea tehnicilor hibride se bazează pe combinarea a două sau mai multe tehnici pentru a beneficia de avantajele acestora pentru a obține o segmentare mai bună. Această combinație poate produce o precizie de segmentare mai bună, în special pentru aplicațiile de segmentare IRM a creierului. [5]

## Capitolul 3 : Descrierea Metodelor Propuse

### 3.1. Îmbunătățirea imaginilor

Metodele alese pentru a fi implementate în vederea detecției tumorii în imagini sunt: modificarea contrastului liniară pe porțiuni, funcția putere și clipping-ul.

#### 3.1.1. Modificarea contrastului, liniară pe porțiuni

Ajustările liniare de contrast utilizează o funcție de mapare liniară pentru a extinde un interval de intensități ale pixelilor de intrare.[6]

Ajustarea liniară a contrastului extinde liniar valorile originale ale pixelilor într-o gamă nouă de valori, astfel încât să fie utilizat întregul domeniu de sensibilitate. Metoda folosește două praguri, unul minim și unul maxim, între care este definit domeniul de sensibilitate de interes.[7]

Contrastul (C) = diferența dintre un obiect (f) și zona de fundal (b) [7]

$$C = \frac{f-b}{f+b} = \frac{\Delta v}{\Delta u} = \frac{T(v_2)-T(v_1)}{u_2-u_1} = \frac{dT(u)}{du} = T(u) \quad (3.1)$$

Metoda se bazează pe o funcție de transfer definită pe intervale, care ajustează intensitățile între două puncte fixe (0,0 și L-1,L-1) și două puncte de control (a,T<sub>a</sub> și b, T<sub>b</sub>). Intensitățile inițiale sunt scalate liniar pe trei intervale distincte, pentru a evidenția detalii în anumite zone ale imaginii, îmbunătățind contrastul.[8]

$$T(x) = \begin{cases} \frac{T_a}{a}x, & x \in [0, a] \\ T_a + \frac{T_b-T_a}{b-a}(x-a), & x \in [a, b] \\ T_b + \frac{L-1-T_b}{L-1-b}(x-b), & x \in [b, L-1] \end{cases} \quad (3.2)$$

Unde L = 256,




Fig 3.1

### 3.1.2. Funcția putere

Funcția putere este utilă pentru îmbunătățirea contrastului în scopuri generale. Este o transformare neliniară a imaginii, având nivelele de gri extreme ca puncte fixe: (0, 0) și (L-1, L-1). [8]

$$V = T(u) = (L-1) \left( \frac{u}{L-1} \right)^r \quad (3.3)$$

Unde  $r$  este parametru de reglaj.




Fig 3.2

Din (3.3) o regiune întunecată a imaginii va avea o valoare exponențială  $r < 1$ , fiind similară cu funcția logaritmică, iar o regiune luminoasă va avea o valoare exponențială  $r > 1$ , fiind similară cu funcția exponențială. [9]

### 3.1.3. Clipping

Aceasta presupune eliminarea valorilor pixelilor dintr-o imagine care se află în afara unui interval definit  $[a, b]$ , fiind fixate la valoarea 0. În interiorul intervalului  $[a, b]$ , pixelii sunt scalați liniar conform relației :

$$T(x) = \begin{cases} 0, & x \in [0, a) \\ T_a + \frac{T_b - T_a}{b - a} (x - a), & x \in [a, b) \\ 0, & x \in [b, L) \end{cases} \quad (3.4)$$




Fig 3.3

Unde  $T_a$  și  $T_b$  sunt valorile asociate limitelor intervalului  $[a, b]$ . Graficul arată cum valorile sunt complet eliminate în afara intervalului, iar în interior, există o creștere liniară între  $T_a$  și  $T_b$ .

Aceasta metodă este utilizată pentru a accentua detaliile dintr-o gamă specifică de intensități, eliminând zgomotul sau valorile irelevante din imagine.[8]

### 3.2. Segmentare

Segmentarea k-means este un algoritm de învățare automată nesupravegheată folosit pentru a organiza datele în clustere (grupuri) pe baza caracteristicilor sale. Scopul principal este de a împărți datele într-un număr specificat de grupuri, fiecare fiind caracterizat de un centroid.

Procesul funcționează astfel:

- Se inițializează k centre(centroizi) aleatorii;
- Pentru fiecare pixel din imagine, se calculează distanța Euclidiană  $d$ , dintre centre și pixel;

$$d = \|p(x, y) - c_k\| \quad (3.5)$$

- Se alege cel mai apropiat centru de pixel;
- După ce toți pixelii au fost atribuiți, se recalculează noua poziție a centrului;

$$c_k = \frac{1}{k} \sum_{y \in C_k} \sum_{x \in C_k} p(x, y) \quad (3.6)$$

- Se repeta pașii până se ajunge la o toleranță satisfăcătoare;
- Se remodelează pixelii în funcție de centrul.

În cazul nostru se vor alege  $k = 2$  centre, ceea ce va împărți imaginea gri în două categorii: alb și negru, astfel după aplicarea algoritmului se va obține o imagine binarizată cu zonele de interes.[12]




Fig 3.4 Algoritmul k-means pentru  $k = 3$  centroizi, ilustrate în culori.

### 3.3. Operații morfologice

Acest tip de operații se aplică imaginilor binare în etapa de preprocesare pentru a modifica forma sau structura obiectelor din imagine. Operațiile morfologice principale includ dilatarea, erodarea, deschiderea (opening) și închiderea (closing), fiecare având scopul de a ajusta contururile și detaliile obiectelor, în funcție de cerințele procesării ulterioare.[10]

Operațiile care au fost alese pentru a fi aplicate pe setul de date sunt dilatarea și erodarea.

#### 3.3.1. Dilatarea

Funcția de dilatare este o operație morfologică aplicată imaginilor, care extinde regiunile de prim-plan prin adăugarea de pixeli la marginile obiectelor. În contextul reducerii zgomotului din imaginile color, dilatarea utilizează un element structural de dimensiune  $3 \times 3$  pentru a identifica și elimina pixelii corupți (cu valori extreme, 0 sau 255). Acești pixeli sunt înlocuiți cu valoarea mediană a pixelilor necorupți din vecinătate, asigurând o reducere eficientă a zgomotului, chiar și la densități cuprinse între 10% și 90%.[11]




Fig 3.5 Tehnica ferestrei glisante asupra dilatării obiectului

### 3.3.2.Erodarea

Procesul de erodare reduce dimensiunea structurilor din prim-planul imaginii. Prin urmare, imaginile finale vor avea o zonă de fundal mai mare comparativ cu imaginile inițiale. Un element structural în formă de pătrat  $3 \times 3$  scanează imaginea de intrare. Procesul de erodare are loc atunci când elementul structural se potrivește complet cu structurile din prim-planul imaginii de intrare.[11]




Fig 3.6 Tehnica ferestrei glisante asupra erodării obiectului

## Capitolul 4 : Rezultate obținute

Setul de 10 imagini (Fig 4.1) pentru acest proiect a fost selectat din Brain Tumor MRI Dataset de pe platforma Kaggle. În această bază de date există 4 clase de imagini : fără tumori, gliomul, meningiomul si hipofiza. Imaginile alese au ca zonă de interes meningiomul.




Fig 4.1. Setul de imagini

Schema procesului este prezentata mai jos:

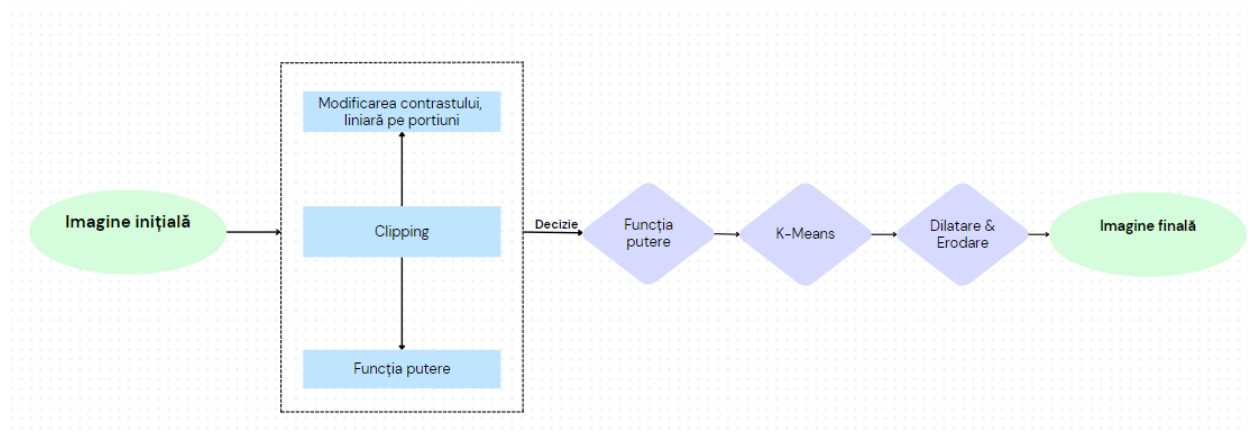


Fig 4.2. Schemă de proces

#### 4.1. Îmbunătățirea imaginilor

Pentru a prezenta rezultatele obtinute am ales Imaginea 8 (Te-me\_0026.jpg) din setul de date.

Imagine 8




Fig 4.3.

În continuare vor urma cele trei operații de îmbunătățire a imaginilor aplicate imaginii.

##### 4.1.1. Modificarea contrastului, liniară pe porțiuni






Fig 4.4

#### 4.1.2. Functia putere




Fig 4.5

#### 4.1.3. Clipping




Fig 4.6

Din punct de vedere vizual, modificarea contrastului pe porțiuni aplică o transformare locală, în funcție zonele specifice, dar nu ajută la eliminarea fundalului imaginii, în schimb funcția putere aplică o transformare globală care elimină semnificativ fundalul, zona de interes observându-se foarte clar. Operația de clipping accentuează doar conturul leziunii, fundalul fiind la fel ca și interiorul acesteia.

Ca urmare a observațiilor de mai sus, operația “câștigătoare” este funcția putere.

#### 4.2. Segmentare

Pentru operația de segmentare, folosind algoritmul k-means, se obțin rezultate satisfăcătoare în marea majoritate a cazurilor.




Fig 4.7

#### 4.3. Operații morfologice

La această etapă am încercat mai multe operații, dar cele mai bune rezultate le-am obținut prin aplicarea succesivă a operațiilor de dilatare și erodare.

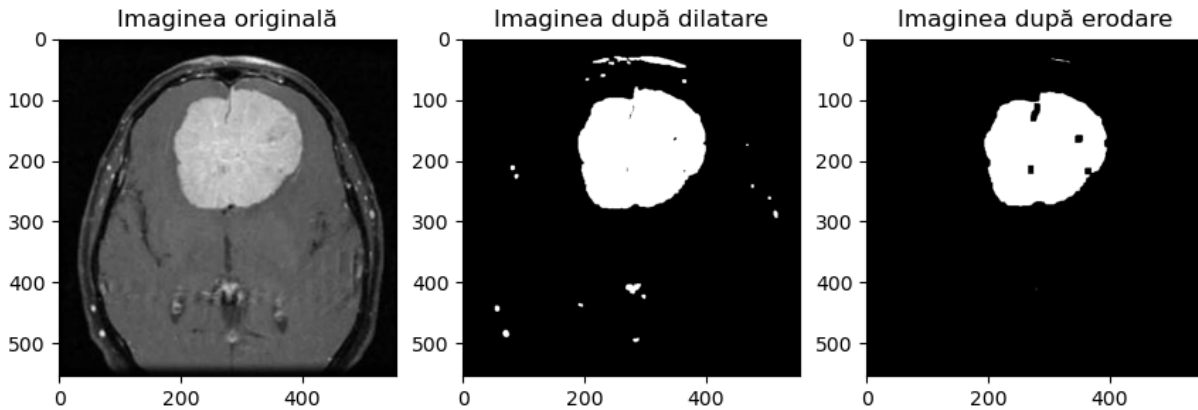


Fig 4.8

În urma dilatării se extinde zona de interes, dar se mai observa și alte regiuni mici nedorite. Prin aplicarea succesivă și a erodării regiunile nedorite din jurul leziunii au dispărut, iar în imagine a rămas numai tumoarea, astfel se poate face o localizare clară a acesteia.




Fig 4.9 Etapele parcurse

#### 4.4. Rezultate satisfăcătoare și nesatisfăcătoare

Diferența dintre un rezultat bun și unul mai puțin bun este reprezentată de nivelurile de gri ale regiunilor din imagine. Dacă nivelurile de gri ale zonei de interes sunt similare cu ale celorlalte

regiuni atunci imaginea finala va fi mai puțin sau deloc bună, altfel dacă nivelurile de gri ale leziunii sunt foarte îndepărtate de ale celorlalte zone din imagine atunci rezultatul va fi unul bun.

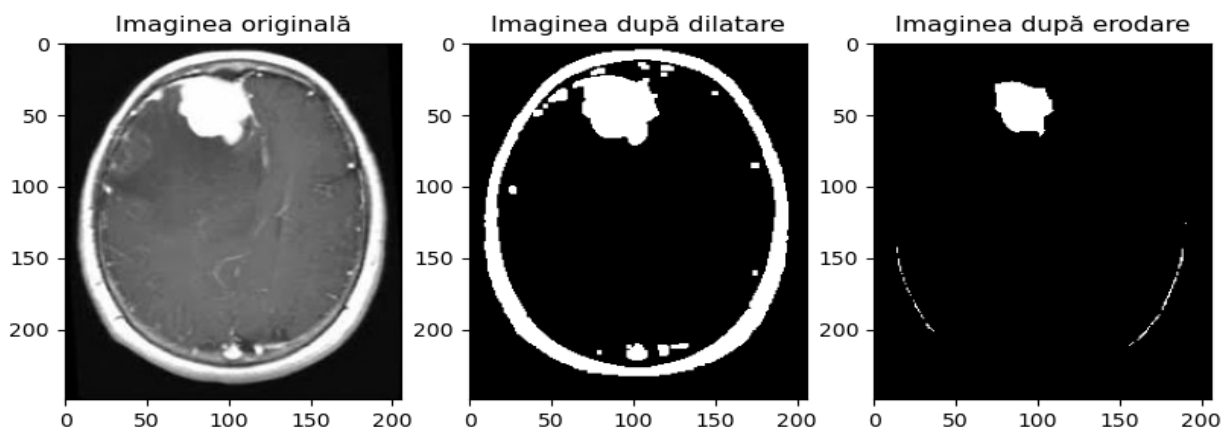


Fig 4.10 Rezultat satisfăcător




Fig 4.11 Rezultat nesatisfăcător

## Capitolul 5 : Concluzii

În urma procesării imaginilor se obțin rezultate satisfăcătoare pentru a analiza prezenta unui tumorii pe imaginile IRM, acestea fiind evidențiate pentru analiza. Procesul poate elimina complet sau parțial și cutia craniului din imagine, fiind mai ușor de a identifica tumoarea față de alte erori.

În rare cazuri, când contrastul dintre creier și tumoare este identic, se vor produce erori la segmentarea imaginii, deoarece algoritmul k-means face analiza în funcție de intensitatea pixelilor, când se întâmplă aceasta, în imaginea finală sunt prezente mai multe erori pe lângă tumoare, astfel procesul de analiză este îngreunat. Astfel pentru o eficiență ridicată se poate adăuga la etapa de segmentare o metodă mai avansată de detecție a tumorii, de exemplu detecție de obiecte folosind CNN-uri, care sunt capabile să detecteze o tumoare și să delimiteze poziția sa.

Contribuția personală a fost crearea unei rutine de segmentare a imaginii, folosind algoritmul k-means, configurat pentru binarizare, care a obținut rezultate satisfăcătoare în delimitarea tumorilor.

Pentru operațiile morfologice, am ajuns la concluzia că o combinație dintre dilatare și erodare este preferată, procesarea doar cu una dintre ele a evidențiat erorile prezente sau a micșorat tumoarea, prin combinația propusă am obținut un echilibru între erori și informație utilă, am testat și posibilitatea folosirii de mai multe ori a unei singure operații sau a altor combinații între cele două.

Pentru perspective de dezvoltare se poate studia o metodă mai bună pentru segmentare, menționată mai sus, sau o rutină de îmbunătățire a imaginii care să scoată în evidență informația utilă, acesta fiind un punct slab în acest program.

## Bibliografie

- [1] Budday, Silvia, Paul Steinmann, and Ellen Kuhl. "Physical biology of human brain development." *Frontiers in cellular neuroscience* 9 (2015): 257.
- [2] Wiemels, Joseph, Margaret Wrensch, and Elizabeth B. Claus. "Epidemiology and etiology of meningioma." *Journal of neuro-oncology* 99 (2010): 307-314.
- [3] Katti, Girish, Syeda Arshiya Ara, and Ayesha Shireen. "Magnetic resonance imaging (MRI)—A review." *International journal of dental clinics* 3.1 (2011): 65-70.
- [4] Mohammed, Yahya MA, Said El Garouani, and Ismail Jellouli. "A survey of methods for brain tumor segmentation-based MRI images." *Journal of Computational Design and Engineering* 10.1 (2023): 266-293.
- [5] Mohammed, Yahya MA, Said El Garouani, and Ismail Jellouli. "A survey of methods for brain tumor segmentation-based MRI images." *Journal of Computational Design and Engineering* 10.1 (2023): 266-293.
- [6] Bourne, Roger, and Roger Bourne. "Contrast adjustment." *Fundamentals of Digital Imaging in Medicine* (2010): 109-135.
- [7] R. Klein, C.E. Myers, K.E. Lee, R. Gangnon, B.E. Klein, Changes in retinal vessel diameter and incidence and progression of diabetic retinopathy. *Arch Ophthalmol.* 130:749-755, 2012. PMID: 22332203
- [8] Laborator 4 Imagistică Medicală. „Tehnici de îmbunătățire a imaginilor medicale” (2024)
- [9] Tsai, Chun-Ming. "Adaptive local power-law transformation for color image enhancement." *Applied Mathematics & Information Sciences* 7.5 (2013): 2019.
- [10] Laborator 5 Imagistică Medicală. „Elemente teoretice de Filtrare și Morfologie” (2024)
- [11] Said, Khairul Anuar Mat, and Asral Bahari Jambek. "Analysis of image processing using morphological erosion and dilation." *Journal of Physics: Conference Series*. Vol. 2071. No. 1. IOP Publishing, 2021.



[12] Dhanachandra, Nameirakpam, Khumanthem Manglem, and Yambem Jina Chanu. "Image segmentation using K-means clustering algorithm and subtractive clustering algorithm." *Procedia Computer Science* 54 (2015): 764-771.



**UNIVERSITATEA POLITEHNICA BUCUREȘTI**  
**Facultatea de Electronică, Telecomunicații și Tehnologia informației**

